

结构化字段之外， 文本还剩多少 Alpha?

以 A 股业绩预告为例的
可解释因子智能体与增量检验

How Much Alpha Remains in Text Beyond Structured Fields?

An Explainable Factor Agent and Incremental Test

Using A-Share Performance Forecasts



RESEARCH TEAM

周梓煜 (组长) 张心湑 许艺馨 张修博 刘迅羽 王佳祺

摘要

本文研究一个可证伪的问题：当同一事件的关键数字已经以结构化字段公开时，大语言模型（LLM）从公告正文中提取的语义还能否提供增量 Alpha？我们以 2019–2021 年 A 股业绩预告为检验场，构建“结构化预告幅度”对照组，并设计“结构化字段 + 文本语义”处理组。系统遵循严格职责边界：LLM 只提出假说与解释结果，字段校验、点时间对齐、因子计算、横截面中性化、样本外评价和终局裁决全部由确定性代码完成，回测过程中不调用 LLM。

真实数据包含 39,294 条业绩预告原始记录、13,283 条可用于增长幅度对照的事件，以及覆盖 2015–2021 年、5,809,082 个股票—交易日观测的点时间面板。结构化对照因子取预告增长率区间中点，在披露日的下一交易日起生效，以 20 日复权前向收益评价。60 日持有、复权并完成市值和行业中性化后，全样本平均 Rank IC 为 0.0278，ICIR 为 0.3658；考虑重叠收益后的 Newey–West t 值为 2.56。但分年度结果从 2019 年的 0.0490、2020 年的 0.0467 下降到 2021 年封存测试段的 -0.0049 ，说明样本内强度没有在最终年度延续。

公告原文已经落地，且可得性规则已登记；然而，处理组仍缺少冻结模型版本、文本哈希缓存与可复现的离线语义特征。因此本文不填造文本增量指标，终局结论为“证据不足”，而不是“文本有效”或“文本无效”。本文的主要贡献是一个能诚实拒绝未来字段、重复候选和证据不完整结论的研究装置：它把可解释性前移到假说生成阶段，并以不可逆研究闸门和可追溯产物保证数值裁决不受 LLM 影响。

关键词： Alpha 因子；大语言模型智能体；业绩预告；增量检验；点时间对齐；Rank IC；样本外检验

研究结论一句话： 结构化业绩预告幅度在 2019–2020 年表现出横截面预测力，但在 2021 年测试段失效；由于可复现的文本语义处理组尚未形成，当前不能判断“文本是否带来额外 Alpha”，合理结论是证据不足。

目 录

1	引言	4
2	相关工作与研究定位	4
2.1	横截面收益预测与样本外纪律	5
2.2	机器学习、符号回归与 LLM 因子生成	5
2.3	本文的研究空缺	5
3	系统设计与研究治理	5
3.1	职责边界	5
3.2	受限表达式与校验	6
3.3	不可逆研究状态机	6
4	数据、变量与防前视设计	6
4.1	数据来源与样本	6
4.2	点时间可得性	7
4.3	结构化对照与文本处理组	7
5	实证方法	8
5.1	收益标签与横截面评价	8
5.2	市值与行业中性化	8
5.3	重叠收益与 Newey–West 修正	8
5.4	实验口径	9
6	结果	9
6.1	结构化对照的参数邻域	9
6.2	复权与中性化的影响	10
6.3	年度稳定性与封存测试	11
6.4	五分组收益	12
6.5	候选漏斗与主问题裁决	12
7	讨论	13
7.1	结果如何理解	13
7.2	方法论价值	13

7.3 与既有工作的关系 13

8 有效性威胁与局限 14

9 后续工作 14

10 结论 14

可复现性与产物映射 15

参考文献 15

1 引言

传统因子研究通常走两条路线：研究员从经济机制出发手工提出变量，或由遗传规划、符号回归与机器学习在大规模表达式空间中搜索。前者有解释但速度慢，后者搜索效率高，却容易产生事后解释、数据挖掘和样本外衰减。资产定价文献早已表明，公开后的因子收益会显著下降，样本内漂亮并不等于可交易的稳定规律 [3]；机器学习虽能容纳非线性和高维交互，也仍必须依赖严格的时间切分与样本外评估 [4]。

LLM 为因子研究带来一种新的可能：模型可以用自然语言组织经济机制，再把假说翻译成结构化、受限的表达式。近期工作已探索 LLM 生成可执行 Alpha 候选与多智能体评价 [5]，符号回归方向也在尝试用 Transformer 直接生成因子表达式 [6]。但“能生成”并不是一个研究结论。若模型同时写代码、看测试结果并裁定因子优劣，系统会把假说提出者、运动员和裁判合并为同一角色，数值幻觉与自动化数据窥探便难以区分。

本文因此把问题收窄为一个明确的增量检验：

公告文本语义是否在结构化业绩预告字段之外提供样本外 Rank IC 增量？

业绩预告适合这一设计，因为增长区间、预告类型与利润区间已经结构化；LLM 的合理位置不是重新描述这些数字，而是识别归因、持续性、不确定性和一次性事项等语义。仅结构化字段的因子构成控制组，结构化字段加文本语义构成处理组。若文本增量为正，说明正文中存在未被结构化字段吸收的信息；若增量不显著，同样是完整结论。若处理组证据缺失，则必须停在“证据不足”，不能用模拟值填空。

本文贡献。

1. 提出一个**假说先行、数值隔离**的可解释因子智能体。LLM 只负责提出候选与阅读结果，回测、显著性和终局状态由纯代码生成。
2. 把防前视约束落实为**点时间数据契约**。公告在日期信息不含精确时刻时统一于下一交易日生效，财务记录只在公告日之后可见。
3. 设计**不可逆研究闸门**：合同确认后冻结定义域与时间切分，验证尝试只增不减，测试段拆封后禁止回退。
4. 在聚源真实数据上完成结构化对照的确定性实证，并公开报告其 2021 年失效与文本处理组缺证据的状态，避免把研究系统包装成必然成功的 Alpha 机器。

2 相关工作与研究定位

2.1 横截面收益预测与样本外纪律

本文关注的是同一交易日不同股票之间的相对排序，而不是单只股票收益的时间序列点预测。经典 Fama–MacBeth 方法先在每个时期做横截面回归，再对时期系数求均值 [1]；工业界常用的 Rank IC 也遵循相同的“先横截面、后时间聚合”思想。两者都要求特征在预测时点真实可得。

McLean 与 Pontiff 对已发表预测变量的研究表明，收益可预测性在样本外及论文发表后明显衰减 [3]。这使得日期有序切分、参数邻域与最终封存测试比单个样本内最优点更重要。本文不采用随机打乱，避免未来市场状态渗入训练阶段。

2.2 机器学习、符号回归与 LLM 因子生成

Gu、Kelly 与 Xiu 展示了机器学习在经验资产定价中的潜力，同时也强调样本外比较的重要性 [4]。AlphaFormer 将因子发现表述为端到端符号回归，目标是直接生成可解释数学表达式 [6]。Kou 等提出由 LLM 生成 Alpha 候选并经多智能体系统筛选的框架 [5]。

本文与上述研究的差异不在搜索能力更强，而在权限边界更窄：不设置自由代码生成 Agent，也不设置以自然语言裁定数值结果的 Eval Agent。候选只能使用登记字段和白名单算子；评价器不能被提示词改变；测试集结果不能流回候选改写。这一“受限自主”是可信度设计，而不是功能缺失。

2.3 本文的研究空缺

结构化事件数据与公告正文往往描述同一事实。如果只报告文本因子的单独 IC，就无法区分模型是否只是复述结构化数字。本文用处理组—对照组框架把 LLM 的必要性本身变成待检验对象，并允许三种终态：正向、负向、证据不足。

3 系统设计与研究治理

3.1 职责边界

系统由研究合同、生成材料、候选池、规则校验、确定性回测、证据存储和结论模块构成。图 1 中，金色模块允许 LLM 参与语言任务，蓝色模块只运行确定性代码。




图 1: 系统权限边界。LLM 参与候选语言和结果解释，但所有数值、验证预算、测试拆封与终局状态均由确定性代码控制。

3.2 受限表达式与校验

候选因子以结构化对象保存，包含名称、受限表达式、经济逻辑、字段依赖、知识来源与风险。表达式引擎只允许算术及 `rank`、`ts_mean`、`ts_std`、`delay`、`delta`、`safe_div` 等白名单算子。属性访问、文件读写、网络请求和任意函数调用均被拒绝。

规则校验先于语义查重，检查字段是否存在、是否登记可得性、是否引用未来收益标签、表达式是否可解析。语义模型只负责解释“是否可能与既有因子重复”，不能推翻规则拒绝。

3.3 不可逆研究状态机

研究流程按以下八个节点推进：

线索 → 合同 → 材料 → 候选池 → 校验 → 训练 + 验证 → 测试拆封 → 结论。

合同确认后，股票池、日期、字段、目标期限和可证伪断言被哈希冻结；验证阶段每个假说最多消耗两次修改预算，回滚不返还；测试拆封后禁止新增验证修改。最终只允许 `positive`、`negative` 或 `insufficient_evidence`。

本次记录的运行编号为 `run-forecast-increment-20260724-01`。离线回放中的每个数值都引用已落盘产物，页面不能自行注入数字。需要说明的是，当前 `run record` 是在确定性结果生成后导出的审计记录，能够证明展示数字与产物一致，但不能等同于第三方时间戳的前瞻性预注册；该限制在第 8 节讨论。

4 数据、变量与防前视设计

4.1 数据来源与样本

核心数据来自学校提供的聚源 JYDB，本地原始数据不进入公共仓库。表 1 给出本次论文使用的数据范围。行情—财务点时间面板覆盖 2015 年 1 月 5 日至 2021 年 12 月 31 日，共 5,809,082 个股票—交易日观测、4,289 只股票。业绩预告原始表含 39,294 条记录、

4,090 个证券代码，公告正文列全部非空；要求增长率区间可构造、去重并映射到交易日后，结构化对照使用 13,283 条事件。

表 1: 真实数据样本概况

数据集	记录数	证券数	起始日期	结束日期
业绩预告原始表	39,294	4,090	2019-06-03	2021-12-31
可用结构化事件	13,283	—	2019-06-03	2021-12-30
点时间股票面板	5,809,082	4,289	2015-01-05	2021-12-31

研究合同把 2019 年作为训练观察期、2020 年作为验证期、2021 年作为最终测试期。面板虽然从 2015 年开始，但可用业绩预告事件始于 2019 年 6 月，因此本次事件实证的有效时间跨度只有约两年半；我们不把更早的无事件面板观测误写成事件样本。

4.2 点时间可得性

定义 1 (点时间可见集). 对交易日 T 与股票 i ，点时间可见事件集为

$$\mathcal{E}_i(T) = \{e : \text{code}(e) = i, \text{effective_date}(e) \leq T\}.$$

若公告只有日期而没有可靠的盘中时刻，则

$$\text{effective_date}(e) = \text{next_trading_date}(\text{InfoPublDate}(e)).$$

交易日 T 的事件因子只允许依赖 $\mathcal{E}_i(T)$ 中最新事件。

命题 1 (无主动前视). 若供应商 `InfoPublDate` 真实反映首次披露日期，交易日历正确，且因子只读取定义 1 的可见集，则在 T 日构造的事件因子不会主动使用披露日晚于或等于 T 且尚未生效的记录。

说明. 实现使用交易日历的 `searchsorted(..., side="right")` 将事件映射到严格晚于披露日的第一个交易日，并断言所有生效日均满足 `eff_date > InfoPublDate`。若持有期内出现新预告，最新已生效事件覆盖旧事件。同一披露日对应多个报告期时，只保留最近报告期，避免把下一年度指引混入当期信号。

4.3 结构化对照与文本处理组

结构化对照的原始信号为预告增长率上下界的中点：

$$g_e = \frac{\text{EGrowthRateFloor}_e + \text{EGrowthRateCeiling}_e}{2}.$$

信号从下一交易日起持续 $h \in \{20, 40, 60\}$ 个交易日；同日横截面按 1% 与 99% 分位缩尾。60 日为先行主口径，20/40 日用于参数邻域描述，而不是从连续网格中挑选最优尖峰。

文本处理组计划从 **ForcastContent** 中提取归因类型、持续性、管理层不确定性和一次性事项等语义，再比较“结构化字段 + 文本”相对“仅结构化字段”的增量。原始正文和下一交易日可得规则已经登记，但截至本次运行，尚未形成满足以下条件的处理组产物：固定模型版本、固定提示模板、文本哈希、离线缓存、输出模式验证以及逐事件可追溯特征。系统因此按 fail closed 原则不计算文本增量。

5 实证方法

5.1 收益标签与横截面评价

令 $P_{i,t}^{adj}$ 为复权收盘价，主要收益标签为 20 日前向收益：

$$R_{i,t}^{(20)} = \frac{P_{i,t+20}^{adj}}{P_{i,t}^{adj}} - 1.$$

对每个交易日计算 Spearman 秩相关：

$$\text{RankIC}_t = \text{corr}\left(\text{rank}(f_{i,t}), \text{rank}(R_{i,t}^{(20)})\right), \quad \text{ICIR} = \frac{\overline{\text{RankIC}}}{\sigma(\text{RankIC})}.$$

只有当日有效事件截面不少于 30 只股票时，该日才计入 IC 序列。

5.2 市值与行业中性化

为减少结构化预告幅度对公司规模和行业的被动暴露，在每个交易日做横截面 OLS：

$$f_{i,t} = \alpha_t + \beta_t \log(\text{MktCap}_{i,t}) + \sum_k \gamma_{k,t} \mathbf{1}(\text{Industry}_{i,t} = k) + \varepsilon_{i,t}.$$

最终因子取残差 $\hat{\varepsilon}_{i,t}$ 。行业标签按历史生效期展开，市值来自当日数据或 PIT 可见股本与收盘价的乘积。诊断结果显示，60 日完整中性化残差与对数市值的相关系数为 8.82e-17，行业一日期组残差均值最大绝对值为 2.23e-09；这证明数值残差化已经执行，但不意味着经济暴露在所有组合构造中完全消失。

5.3 重叠收益与 Newey–West 修正

20 日前向收益高度重叠，逐日 IC 并非独立。朴素 t 值会高估精度，因此本文以 20 阶 Bartlett 权重的 Newey–West 修正作为主要显著性参考 [2]：

$$\hat{\Omega} = \hat{\gamma}_0 + 2 \sum_{k=1}^{20} \left(1 - \frac{k}{21}\right) \hat{\gamma}_k, \quad t_{NW} = \frac{\overline{\text{RankIC}}}{\sqrt{\hat{\Omega}/T}}.$$

朴素 t 值只用于展示重叠造成的膨胀程度，不作为结论依据。

5.4 实验口径

表 2: 主实验设置

项目	设置
市场与频率	A 股，日频
控制组	业绩预告增长率区间中点
处理组	控制组 + 冻结离线文本语义特征（本轮缺失）
信号可用日	披露日后的下一交易日
信号持有期	60 日主口径；20/40 日邻域
收益标签	20 日复权前向收益
预处理	日截面 1%/99% 缩尾，市值与行业中性化
最小截面	30 只股票
主要指标	Rank IC、ICIR、Newey–West t 、五分组收益
结论状态	正向 / 负向 / 证据不足

6 结果

6.1 结构化对照的参数邻域

表 3: 持有期参数邻域：完整中性化口径

持有期	Rank IC	ICIR	朴素 t	Newey–West t	有效日数
20	0.0134	0.0998	2.36	0.91	559
40	0.0244	0.2763	6.73	1.96	594
60	0.0278	0.3658	8.91	2.56	594

表 4: 60 日持有口径的逐步修正与稳健性检验

口径	Rank IC	ICIR	朴素 t	Newey–West t	有效日数
A 未复权	0.0448	0.3681	8.97	2.46	594
B 复权	0.0501	0.4053	9.88	2.70	594
C 复权 + 市值中性	0.0490	0.4989	12.16	3.34	594
D 复权 + 市值 + 行业中性	0.0278	0.3658	8.91	2.56	594

表 3 与图 2 显示，完整中性化后的平均 Rank IC 随持有期从 20 日的 0.0134 提升到 60 日的 0.0278。20 日口径的 Newey–West t 只有 0.91，40 日为 1.96，60 日为 2.56。该邻域没有出现单一窄尖峰，但它是全时段描述性结果，不能替代最终年度测试。




图 2: 完整中性化结构化因子在 20/40/60 日持有邻域的平均 Rank IC。数值由确定性结果文件直接生成。

6.2 复权与中性化的影响

表 4 与图 3 给出 60 日口径的四档修正。复权使 Rank IC 从 0.0448 上升至 0.0501；仅做市值中性化后为 0.0490；进一步加入行业中性化后降至 0.0278。行业中性化带来约 0.0212 的 IC 降幅，说明原始信号相当一部分与行业构成相关。完整口径仍有正的全样本 IC，但不能把中性化前的更高数字当作纯粹个股选择能力。




图 3: 60 日结构化对照因子的复权与中性化消融。

6.3 年度稳定性与封存测试

图 4 是本文最关键的结果。完整中性化、60 日持有口径在 2019 年和 2020 年的年度 Rank IC 分别为 0.0490 和 0.0467，但 2021 年降至 -0.0049。也就是说，全样本 0.0278 的正 IC 主要来自训练和验证阶段，最终年度没有延续。




图 4: 60 日完整中性化结构化因子的分年度 Rank IC。2021 年为最终测试年度。

这一结果不支持“结构化预告幅度在 2021 年仍有稳定 Alpha”的强结论。它可能反映市场状态变化、事件样本构成变化、信号衰减或开发期偶然性；仅凭三年数据无法区分这些解释。更重要的是，处理组尚未形成，因此不能从结构化因子的失效推导“文本一定有效”。

6.4 五分组收益

60 日完整中性化信号的五分组平均 20 日前向收益为：Q1 1.52%、Q2 1.63%、Q3 2.24%、Q4 2.16%、Q5 2.38%，Q5-Q1 差约 0.86 个百分点。图 5 显示总体从低组向高组上升，但 Q3 高于 Q4，并非严格单调。由于持有窗口重叠、尚未构造真实换手与交易成本序列，本文不把该差值解释为可直接交易的成本后收益。




图 5：60 日完整中性化信号的五分组平均 20 日前向收益。

6.5 候选漏斗与主问题裁决

本次记录保留三个代表性候选：结构化预告幅度对照通过确定性校验并完成回测；把未来收益当作当期输入的候选被规则层拒绝；文本增量候选因缺少冻结、可复现的语义特征缓存而不可回测。漏斗为“记录 3 个—通过 1 个—拒绝 1 个—证据不可用 1 个”。

表 5：候选漏斗与裁决理由

候选	状态	裁决理由
结构化预告幅度	通过	字段、PIT 生效日、复权收益与中性化证据齐全，完成确定性回测。
未来收益反推方向	拒绝	未来收益只能作为标签，不能成为 T 日因子输入。
公告文本增量	不可用	原文已落地，但冻结模型、提示模板、哈希缓存和可复现语义特征缺失。

因此，主问题“文本是否在结构化字段之外提供增量 Alpha”在本轮的唯一合规结论

是：

insufficient evidence（证据不足）

这不是统计意义上的“接受零假设”。它表示处理组尚未被合法构造，增量 IC 不能计算。任何正向或负向文本结论都超出了现有证据。

7 讨论

7.1 结果如何理解

结构化预告幅度在 2019–2020 年有较强横截面排序能力，但行业中性化明显削弱信号，且 2021 年转为轻微负值。一个保守解释是：管理层披露的增长幅度在开发期包含信息，但其有效性依赖行业与市场状态，不能视为稳定、跨期的个股 Alpha。本文没有足够证据判断失效来自定价效率提升、样本结构变化还是信号定义本身。

文本处理组缺失也暴露了 LLM 金融研究的关键难点：原始文本“存在”不等于特征“可回测”。可复现的文本因子至少需要固定输入文本、固定模型与提示、输出模式、内容哈希、缓存命中、失败记录和离线重放。否则模型版本漂移或重复 API 调用会让同一公告在不同时间得到不同特征，回测便无法审计。

7.2 方法论价值

系统最重要的产出不是某个高 IC 数字，而是三种拒绝能力：

1. 拒绝未来字段进入因子；
2. 拒绝用朴素显著性掩盖重叠样本相关；
3. 拒绝在处理组缺证据时给出想要的结论。

这使“解释”成为因子出生时的结构化假说，而不是看到结果后补写的故事。LLM 可以扩大语义搜索空间，但不能改变数值裁决。

7.3 与既有工作的关系

已有 LLM 量化系统往往强调自动生成和策略收益 [5]。本文选择更窄的职责分割：生成器可以提出文本语义假说，但代码生成和结果裁决不交给模型。与 AlphaFormer 等符号回归工作 [6] 相比，本文不追求端到端最优，而是强调每个字段的可得日、每个实验阶段的不可逆性与每个数字的产物来源。两类路线并不冲突：强搜索器可以作为候选来源，但必须服从同一确定性证据链。

8 有效性威胁与局限

1. **文本处理组尚未完成。**原始公告正文虽已导出，但没有冻结、可复现的语义特征缓存，本文无法真正计算增量 IC。这是主结论停在“证据不足”的直接原因。
2. **事件期较短。**可用结构化事件只覆盖 2019 年 6 月至 2021 年末，训练期不足一年，测试期只有一个自然年，统计功效和市场状态覆盖有限。
3. **参数邻域包含全时段描述。**20/40/60 日 JSON 文件均报告 2019–2021 年总体指标及年度拆分，因此总体邻域只能作为事后稳健性描述，不能当作完全未见测试集的调参证据。论文把 2021 年年度值单独作为最终评价，并披露这一限制。
4. **研究记录不是第三方预注册。**不可逆状态机能阻止软件内回退，但本次离线 run record 在结果文件之后生成，缺少外部时间戳，不能独立证明研究者从未提前查看测试结果。
5. **交易可实施性不足。**当前事件脚本未完整加入 ST、停牌、涨跌停、成交容量、冲击成本和组合换手，五分组差不能直接解释为可交易收益。
6. **供应商与复权假设。**单元测试可以证明本项目代码不主动读取未来公告，却不能单独证明供应商日期无误、公告正文未被事后修订或复权序列不存在事后信息。
7. **显著性口径有限。**本文使用滞后 20 阶的 Newey–West 修正处理重叠收益，但未做事件聚类、公司聚类、多重检验或更广泛的自助法检验。
8. **样本选择。**需要增长率上下界的事件才能进入结构化对照，这会排除只披露利润额或定性预告的公司，可能产生覆盖选择偏差。

9 后续工作

第一，构建可复现的文本语义缓存：以公告正文哈希为键，冻结模型、提示词与输出 schema，记录失败和重试，确保回测完全离线。第二，在新合同中预注册文本特征、结构化控制、增量定义和显著性检验，并由外部时间戳封存 2021 或更新年份的测试证据。第三，扩展事件历史与滚动样本外窗口，加入行业、规模、预告类型和市场状态分层。第四，补充可交易性过滤、换手与成本模型。第五，在多候选生成时使用固定验证预算和多重检验修正，避免自动化 p-hacking。

10 结论

本文没有把“LLM 能生成因子”当作答案，而是把它改写成一个有控制组、处理组和终局状态的增量检验。系统将 LLM 限定在假说与解释空间，将所有数值交给确定性代码，并通过点时间可得性、白名单表达式、Newey–West 修正、日期有序切分和不可逆测试闸门建立证据链。

真实数据结果显示，结构化业绩预告幅度在 2019–2020 年具有正向 Rank IC，但在 2021 年测试段降至 -0.0049 ；行业中性化也显著削弱信号。公告文本原文已经存在，但冻结、可复现的语义特征处理组尚未形成，因此本文不能回答文本增量为正还是为负，最终结论是“证据不足”。

这一结果并非项目失败。相反，一个可信的因子智能体必须有能力说“不知道”，并能指出缺少哪一条证据。本文证明的不是某个稳定 Alpha，而是一套让 LLM 提出假说、让代码做出裁决、让每个结论都能追溯到确定性产物的研究方法。

可复现性与产物映射

本论文数字由脚本从既有确定性 JSON 结果生成，不重新调用 LLM，也不重新估计因子：

```
python scripts/build_final_paper_assets.py
cd paper && latexmk -xelatex -interaction=nonstopmode main.tex
```

关键产物如下：

产物	用途
results/workflow/ forecast_hold_20.json (另含 40/60 日)	参数邻域、消融、年度 IC、Newey–West t 与五分组收益的确定性来源。
results/workflow/ research_run_record. json	冻结合同、候选漏斗、验证预算、测试拆封与终局状态。
results/paper_update/ final/manifest.json	论文数据版本、源文件 SHA-256、输出清单与数值不经 LLM 的声明。
results/paper_update/ final/ 下的 CSV	论文表格的机器可读版本。
results/paper_update/ final/figures/	从 CSV/JSON 同源生成的论文图。

参考文献

[1] Fama, E. F., & MacBeth, J. D. (1973). Risk, return, and equilibrium: Empirical tests. *Journal of Political Economy*, 81(3), 607–636. doi:10.1086/260061.

- [2] Newey, W. K., & West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708. doi:10.2307/1913610.
- [3] McLean, R. D., & Pontiff, J. (2016). Does academic research destroy stock return predictability? *The Journal of Finance*, 71(1), 5–32. doi:10.1111/jofi.12365.
- [4] Gu, S., Kelly, B., & Xiu, D. (2020). Empirical asset pricing via machine learning. *The Review of Financial Studies*, 33(5), 2223–2273. doi:10.1093/rfs/hhaa009.
- [5] Kou, Z., Yu, H., Luo, J., Peng, J., Li, X., Liu, C., Dai, J., Chen, L., Han, S., & Guo, Y. (2025). Automate strategy finding with LLM in quant investment. *Findings of the Association for Computational Linguistics: EMNLP 2025*, 18517–18533. doi:10.18653/v1/2025.findings-emnlp.1005.
- [6] Huang, H., Peng, J., Ding, Z., Li, P., & Chen, T. (2026). AlphaFormer: End-to-end symbolic regression of alpha factors with Transformers. *Proceedings of Machine Learning Research*, 328, 61–82.